

#### O que é a lA Generativa

Fundamentos de IA do Microsoft Azure



#### Agenda

- ☐ Conceitos básicos de IA gerativa
- ☐ Conceitos básicos do Serviço OpenAl do Azure
- ☐ Explore a IA Gerativa Responsável



#### Objetivos de Aprendizado

- ☐ Descreva a IA generativa.
- ☐ Descreva os recursos de grandes modelos de linguagem.
- ☐ Entenda como usar o Azure OpenAl para criar soluções generativas de IA.



#### Conceitos básicos de IA Generativa



#### O que é lA generativa?

IA: imita o comportamento humano usando aprendizado de máquina para interagir com o ambiente e executar tarefas sem instruções explícitas sobre o que gerar.



#### O que é lA generativa?

IA generativa: cria conteúdo original, como IA gerativa que foi incorporada a aplicativos de chat.Os aplicativos de IA gerativa usam entrada em linguagem natural e retornam respostas apropriadas em uma variedade de formatos:



#### O que é lA generativa?



Geração de linguagem natural



Geração de código



Geração de imagem



### Modelos de linguagem grandes

Os aplicativos de IA gerativa são alimentados por LLMs (modelos de linguagem grandes), que são um tipo especializado de modelo de machine learning que você pode usar para executar tarefas de PLN (processamento de linguagem natural), incluindo:



### Modelos de linguagem grandes

- ☐ Determinar sentimento ou classificar de outra forma o texto em idioma natural.
- ☐ Resumir um texto.
- ☐ Comparar várias fontes de texto quanto à similaridade semântica.
- ☐ Geração de nova linguagem natural.



A arquitetura do modelo do transformador consiste em dois componentes principais, ou blocos.



- ☐ Um bloco *codificador* que cria representações semânticas do vocabulário de treinamento.
- ☐ Um bloco *decodificador* que gera novas sequências de linguagem.



- ☐ O texto é *tokenizado* para que cada palavra ou frase seja representada por um token numérico exclusivo.
- ☐ *Inserções* (valores de vetor com várias dimensões) são atribuídas aos tokens




☐ As camadas de *atenção* examinam cada token por vez e determinam valores incorporados que refletem os relacionamentos semânticos entre os tokens.



□ No decodificador, essas relações são usadas para prever a sequência mais provável de tokens.







### Modelos de linguagem grandes - tokenização

Etapa um: tokenização

□ A primeira etapa no treinamento de um modelo de transformador é decompor o texto de treinamento em tokens.



**Frase de exemplo:** Eu ouvi um cachorro latir alto para um gato.

"Eu"=1

"ouvi"=2

"um"=3

"cachorro"=4

"latir"=5

"alto"=6

"para"=7

"gato"=8



#### Grandes modelos de linguagem – tokenização

- ☐ A frase agora é representada com os tokens:
  - [123456738].
- Observe que "um" é tokenizado como 3 apenas uma vez.
- □ Da mesma forma, a frase "Eu ouvi um gato" poderia ser representada com as fichas [1 2 3 8].




### Modelos de linguagem grandes – inserções

Etapa dois: inserções

☐ As relações entre tokens são capturadas como vetores, conhecidos como inserções.



### Modelos de linguagem grandes – inserções



Token	Word	Inserção	
10	Skateboard	[3, 3, 1]	
4	Cachorro	[10,3,2]	
8	Gato	[10,3,1]	
5	Latir	[10,2,2]	
9	Miau	[10,2,1]	



Terceiro passo: atenção

Capture a força das relações entre tokens usando a técnica de atenção.




#### Exemplo:

- ☐ Meta: prever o token após "cachorro".
- ☐ Represente "Ouvi um cachorro" como vetores.
- ☐ Atribua mais peso a "ouvi" e "cachorro".



- ☐ Vários tokens possíveis podem vir depois de cachorro.
- ☐ O token mais provável é adicionado à sequência, nesse caso , "latir".







#### Copilotos

Os copilotos são frequentemente integrados a outros aplicativos e fornecem uma maneira para os usuários obterem ajuda com tarefas comuns a partir de um modelo generativo de IA.



#### Copilotos

Os desenvolvedores podem criar copilotos que enviam prompts para grandes modelos de linguagem e geram conteúdo para uso em aplicativos.




#### Copilotos

Os usuários empresariais podem usar copilotos para aumentar sua produtividade e criatividade com conteúdo gerado por IA.



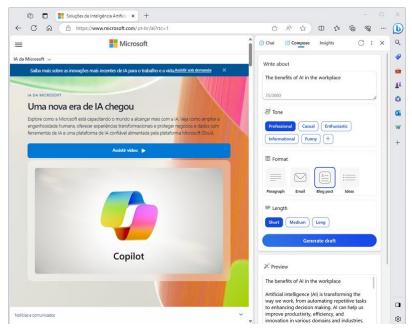
#### Copilots





#### O que são copilotos?


Outros exemplos de copilotos – Navegador Microsoft Edge





#### O que são copilotos?

Outros exemplos de copilotos – Microsoft Bing





#### O que são copilotos?

Outros exemplos de copilotos – GitHub Copilot

```
Arquivo Editar Seleção Ver Acessar Executar Terminal Ajuda
                                                                         • test.js - Visual Studio Code
      ★ Bem-vindo
                         JS test.js 2 •
                             JS test.is
              // find all images without alternate text
              // and give them a red border
\Theta
```



O termo engenharia de prompt descreve o processo de aprimoramento de prompts.



Os desenvolvedores que projetam aplicativos e consumidores que usam aplicativos podem aprimorar a qualidade das respostas da IA gerativa usando linguagem direta, mensagens do sistema, exemplos e/ou dados de fundamentação.



	Descrição	Exemplo
Linguagem direta	Você pode obter conclusões mais úteis sendo explícito sobre o tipo de resposta que deseja.	"Crie uma lista de 10 coisas para fazer em Edimburgo durante o mês de agosto".



	Descrição	Exemplo	
Mensagens do sistema	Descreva como o chat deve funcionar.	"Você é um assistente <b>útil</b> que <b>responde de maneira</b> <b>alegre e</b> amigável".	



	Descrição	Exemplo
Fornecer exemplos	As LLMs geralmente dão suporte ao aprendizado zero-shot no qual as respostas podem ser geradas sem exemplos anteriores. No entanto, você também pode fornecer algumas respostas de exemplo, conhecidas como aprendizado de poucas capturas.	"Visite o castelo pela manhã, antes que as multidões cheguem".



# Aprimorar as respostas de IA generativa com a engenharia de prompts

	Descrição	Exemplo
Dados Básicos	Os prompts podem incluir dados de fundamentação para fornecer contexto.	Incluindo o texto de email com a mensagem "Resumir meu email".



## Conceitos básicos do Serviço OpenAl do Azure



O Serviço OpenAl do Azure é a solução de nuvem da Microsoft para implantar, personalizar e hospedar modelos de linguagem grandes.



O serviço OpenAl do Azure consiste em:

- ☐ Modelos de IA gerativa predefinidos.
- ☐ Funcionalidades de personalização.



☐ Ferramentas integradas para detectar e mitigar casos de uso prejudiciais para que os usuários possam implementar a IA com responsabilidade.



☐ Segurança corporativa com RBAC (controle de acesso baseado em função) e redes privadas.



Você pode usar vários métodos para desenvolver soluções do Azure OpenAI:

- ☐ Estúdio de IA do Azure,
- ☐ API REST,
- ☐ SDKs com suporte e CLI do Azure.



O Azure OpenAl dá suporte a muitos LLMs:	Descrição
GPT-4	Um conjunto de modelos que melhoram o GPT-3.5 e podem compreender e gerar linguagem e código naturais.



O Azure OpenAI dá suporte a muitos LLMs:	Descrição
GPT-3.5	Um conjunto de modelos que melhoram o GPT-3 e podem compreender e gerar linguagem e código naturais.



O Azure OpenAI dá suporte a muitos LLMs:	Descrição
Incorporações	Um conjunto de modelos que podem converter texto em um formulário de vetor numérico para facilitar a similaridade de texto.



O Azure OpenAl dá suporte a muitos LLMs:	Descrição
DALL-E (visualização)	Uma série de modelos em prévisualização que podem gerar imagens originais a partir de linguagem natural.



Estúdio Azure OpenAI:

- ☐ Crie e implante modelos de IA para aplicativos de software
- ☐ Alimentado por modelos generativos de IA otimizados para diversas tarefas



Estúdio Azure OpenAI:

- ☐ Criar e implantar modelos de IA para aplicativos de software
- ☐ Alimentado por modelos de IA gerativa otimizados para tarefas diversas



Estúdio Azure OpenAl:


☐ Modelos Azure OpenAl incluem: modelos GPT-4, GPT-3.5, Embeddings e DALL-E



#### Playgrounds:

- ☐ Experimente modelos Azure OpenAl sem codificação
- ☐ Use a configuração do assistente para instruir o modelo sobre como ele deve se comportar





Fonte: Microsoft



# Funcionalidades de linguagem natural do OpenAl do Azure

Os modelos de GPT (transformadores pré-treinados generativos) são excelentes para entender e criar linguagem natural.



# Funcionalidades de linguagem natural do OpenAl do Azure

Por exemplo, dado um prompt onde o usuário digita um texto solicitando uma receita culinária.

Escreva instruções de receita para uma torta de frutas com base nestes ingredientes:

Strawberries Blueberries Farinha Ovos Leite



# Funcionalidades de linguagem natural do OpenAl do Azure

Exemplo da resposta gerada pelo Azure OpenAl

#### Instruções:

- 1. Pré-aqueça seu forno a 350 graus Fahrenheit.
- 2. Em uma tigela média, misture 1 xícara de farinha e 1 ovo até formar uma massa.
- 3. Unte um prato de torta de 9 polegadas com manteiga ou spray de cozinha antiaderente.
- 4. Enrole a massa e coloque-a no prato de torta.
- 5. Em uma tigela separada, misture 1 xícara de morangos,
- 1 xícara de mirtilos e 1 xícara de leite.
- 6. Despeje a mistura de frutas no prato de torta.
- 7. Gerar



# Recursos de geração de código do OpenAl do Azure

Os modelos GPT traduzem linguagem natural ou trechos de código em código.

A geração de código vai além de apenas escrever código a partir de prompts em linguagem natural.



# Recursos de geração de código do OpenAl do Azure

Considerando o seguinte código, ele pode gerar testes de unidade, conforme mostrado à seguir:

```
Python

# Python 3
def mult_numbers(a, b):
    return a * b

# Unit test
def
```



# Recursos de geração de código do OpenAl do Azure

```
Python
# Python 3
def mult numbers(a, b):
 return a * b
# Unit test
def test mult numbers():
  assert mult numbers(3, 4) == 12
  assert mult numbers(0, 10) == 0
  assert mult numbers(4, 0) == 0
# Unit test
def test mult numbers negative():
  assert mult numbers(-1, 10) == -10
  assert mult numbers(10, -1) == -10
```



☐ Os modelos de IA gerativa podem editar e criar imagens.O modelo que funciona com imagens é chamado DELL-E, que dá suporte à criação de imagem, edição de imagem e criação de variações de imagem.



☐ Geração de imagens: Com o DALL-E você pode até solicitar uma imagem em um determinado estilo. Os estilos também podem ser usados para edições e variações.



☐ Editando uma imagem: DALL-E pode editar a imagem conforme solicitado, alterando seu estilo, adicionando ou removendo itens ou gerando novo conteúdo para adicionar.



□ Variações de imagem: variações de imagem podem ser criadas fornecendo uma imagem e especificando quantas variações da imagem você deseja.



**Prompt:** "Crie quatro variações da imagem de um elefante com um hambúrguer."









Fonte: Microsoft



## lA generativa responsável




# Planejar uma solução de IA generativa responsável

☐ As quatro fases do processo para desenvolver e implementar um plano de IA responsável são:

Identificar, Medida, Mitigar e Operar



# Planejar uma solução de IA generativa responsável



Fonte: Microsoft



#### Hands On!

## "Falar é fácil. Mostre-me o código!"

Linus Torvalds



### Links

- <a href="https://aka.ms/ai900-bing-copilot">https://aka.ms/ai900-bing-copilot</a>
- https://aka.ms/ai900-azure-openai
- <a href="https://aka.ms/ai900-content-filters">https://aka.ms/ai900-content-filters</a>



## Links Úteis

Documentação Oficial



## Dúvidas?

> Fórum/Artigos - https://web.dio.me/articles